

Optimisation non différentiable

Niveau M2

Jour 1 :
Partie 1


Rappels d'Optimisation



Motivation - Pourquoi étudier l'optimisation ?

L'optimisation est partout !

- Trouver le chemin le plus court avec votre GPS
- Entraîner un modèle de Machine Learning pour prédire le cours de la bourse
- Maximiser les profits d'une entreprise en allouant au mieux les ressources
- Concevoir des médicaments plus efficaces
- ... et bien d'autres exemples !




Qu'est-ce que l'optimisation ?





Définition intuitive : Trouver la "meilleure" solution parmi un ensemble de solutions possibles.

Illustration :

- Imaginez une montagne : l'optimisation consiste à trouver le sommet (maximum) ou le point le plus bas de la vallée (minimum).




Types de problèmes d'optimisation - 1/2

Continue  <p>Les variables peuvent prendre n'importe quelle valeur dans un intervalle.</p> <p><i>Optimiser la température d'un four, la vitesse d'une voiture.</i></p>	Discrète  <p>Les variables ne peuvent prendre que des valeurs discrètes (souvent des entiers).</p> <p><i>Choisir le nombre de machines à utiliser, le nombre d'employés à recruter.</i></p>
Sans contraintes  <p>Aucune restriction sur les valeurs des variables.</p> <p><i>Trouver le minimum de la fonction $f: f(x) = x^2$</i></p>	Avec contraintes  <p>Les variables doivent respecter certaines conditions.</p> <p><i>Maximiser le volume d'une boîte avec une surface de carton limitée.</i></p>

Types de problèmes d'optimisation - 2/2


Convexe



Un seul optimum global, plus facile à résoudre.

Exemple : Minimiser $f : f(x) = x^2$

Non convexe



Plusieurs optima locaux, plus difficile à résoudre.

Exemple : Minimiser $g : g(x) = x^4 - 2x^3 + x + 10$

Déterministe



Tous les paramètres du problème sont connus avec certitude.

Exemple : Calculer la trajectoire d'un projectile.

Stochastique



Présence d'aléas.

Exemple : Optimiser un portefeuille d'actions en bourse.

Notions fondamentales - 1/2

- **Fonction objectif** : La fonction mathématique qu'on veut minimiser ou maximiser.

- *Exemple : Coût, profit, temps, erreur.*

$$f(x, y) = 20x - 0.1x^2 + 50y - 0.2y^2$$


- **Espace de recherche** : L'ensemble des solutions possibles.


- *Exemple : Tous les nombres réels, les entiers positifs, un intervalle donné.*



Notions fondamentales - 2/2

- **Solution optimale**
La solution qui minimise ou maximise la fonction objectif.
- **Minimum/maximum local**
Optimal dans un voisinage restreint.
- **Minimum/maximum global**
Optimal parmi toutes les solutions possibles.





Quelques exercices pour commencer :

Rendez-vous au TD 1, exercices I.1 et I.2




Jour 1 :
Partie 2

Optimisation sans contraintes

Optimisation sans contraintes


Objectif : Trouver le minimum ou le maximum d'une fonction sans aucune restriction sur les variables.




Gradient

Le **gradient** est le vecteur indiquant la direction de la plus forte pente. $\nabla f(x)$

Interprétation géométrique : Le gradient est perpendiculaire aux courbes de niveau.



$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \vdots \end{bmatrix}$$




Optimalité du premier ordre

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \vdots \end{bmatrix}$$

Point critique : Un point où le gradient est nul

$$\nabla f(x) = 0$$

Condition nécessaire d'optimalité : Si est un minimum (ou maximum) local, alors est un point critique.



Optimalité du premier ordre


Point critique : Un point où le gradient est nul

$$\nabla f(x) = 0$$

Condition nécessaire d'optimalité : Si est un minimum (ou maximum) local, alors est un point critique.

Attention !

Un point critique n'est pas forcément un minimum ou un maximum (**point selle**).



Hessienne


La Hessienne est la matrice des dérivées partielles secondes. $\nabla^2 f(x)$

Interprétation géométrique : La Hessienne décrit la courbure de la fonction.

Par exemple, le gradient et la hessienne de la fonction $f(x,y)=x^2-y^2$ s'écrivent

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

$$\nabla f(x, y) = \begin{pmatrix} 2x \\ -2y \end{pmatrix} \quad \text{et} \quad \nabla^2 f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$



Optimalité du second ordre

Conditions suffisantes d'optimalité :




- Si $\nabla f(x^*) = 0$ et $\nabla^2 f(x^*)$ est définie positive, alors x^* est un minimum local strict.
- Si $\nabla f(x^*) = 0$ et $\nabla^2 f(x^*)$ est définie négative, alors x^* est un maximum local strict.

Convexité :

- Une fonction est convexe si sa Hessienne est semi-définie positive en tout point.
- Pour une fonction convexe, tout minimum local est global.

Méthodes de descente - Principe général

Idée : Partir d'un point initial et se déplacer itérativement dans la direction de descente (opposée au gradient) pour minimiser la fonction.



Descente de gradient



Algorithme :

1. Initialiser . x_0
2. Répéter jusqu'à convergence :
 - Calculer le gradient . $\nabla f(x_k)$
 - Choisir un pas de descente . α_k
 - Mettre à jour : . $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$

Descente de gradient

Choix du pas de descente :

- Pas fixe
- Pas décroissant
- Recherche linéaire (e.g., méthode de Wolfe)




Descente de gradient

Avantages

Simple à implémenter, peu coûteuse en calcul.

Inconvénients

Convergence peut être lente, sensible au choix du pas.




Descente de gradient

Avantages

Simple à implémenter, peu coûteuse en calcul.

Inconvénients

Convergence peut être lente, sensible au choix du pas.



Variantes :

Descente de gradient stochastique, gradient conjugué, etc.

Méthode de Newton

Principe : Utiliser une approximation quadratique de la fonction pour déterminer la direction de descente.

Formule de mise à jour :

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

$$H(f) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

Méthode de Newton

Avantages : Convergence rapide près de la solution optimale.

Inconvénients :

- Nécessite le calcul de la Hessienne et de son inverse, coûteux en calcul.
- Suppose que la fonction est deux fois différentiable

Variantes : Méthodes quasi-Newton ([BFGS](#)) pour approximer la Hessienne.

Exemple 1 - Minimisation d'une fonction quadratique

$$f(x, y) = x^2 + 2y^2 - 2xy + x - 2y$$

1. Calcul du gradient

Le gradient $\nabla f(x, y)$ est donné par :

$$\nabla f(x, y) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$

Calculons chaque dérivée :

$$\frac{\partial f}{\partial x} = 2x - 2y + 1$$

$$\frac{\partial f}{\partial y} = 4y - 2x - 2$$

Ainsi, le gradient est :

$$\nabla f(x, y) = (2x - 2y + 1, 4y - 2x - 2)$$

Exemple 1 - Minimisation d'une fonction quadratique

$$f(x, y) = x^2 + 2y^2 - 2xy + x - 2y$$

2. Calcul de la Hessienne

La matrice Hessienne H est donnée par les dérivées secondes :

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix}$$

Calculons les dérivées secondes :

$$\frac{\partial^2 f}{\partial x^2} = 2$$

$$\frac{\partial^2 f}{\partial y^2} = 4$$

$$\frac{\partial^2 f}{\partial x \partial y} = -2$$

Donc, la matrice Hessienne est :

$$H = \begin{bmatrix} 2 & -2 \\ -2 & 4 \end{bmatrix}$$

Exemple 1 - Minimisation d'une fonction quadratique

$$f(x, y) = x^2 + 2y^2 - 2xy + x - 2y$$

3. Application de la descente de gradient

La méthode de la descente de gradient met à jour les variables selon la règle :

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ y_k \end{bmatrix} - \alpha \nabla f(x_k, y_k)$$

où α est le taux d'apprentissage.

4. Méthode de Newton

La méthode de Newton met à jour les variables selon la règle :

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ y_k \end{bmatrix} - H^{-1} \nabla f(x_k, y_k)$$


Où H^{-1} est l'inverse de la matrice Hessienne.

Exemple 1 - Minimisation d'une fonction quadratique


$$f(x, y) = x^2 + 2y^2 - 2xy + x - 2y$$

Le code exemple peut être trouvé [ici](#)

Itérations de la descente de gradient et de la méthode de Newton (3D)



Itérations de la descente de gradient et de la méthode de Newton




Exemple 2 - Régression linéaire

Problème : Ajuster une droite à un nuage de points en minimisant la somme des carrés des erreurs.

Fonction objectif : Erreur quadratique moyenne (MSE)

Résolution analytique
vs. Descente de gradient



Exemple 2 - Régression linéaire

Objectif

L'objectif est de minimiser la somme des carrés des erreurs (ou résidus), qui est donné par :

$$\text{Erreur} = \sum (y_i - (mx_i + b))^2$$

où y_i est la valeur réelle pour chaque point x_i .

1. Résolution analytique

La méthode analytique pour ajuster une droite ($y = mx + b$) implique d'utiliser les formules pour le calcul des coefficients m (pente) et b (intercept) :

$$m = \frac{N(\sum xy) - (\sum x)(\sum y)}{N(\sum x^2) - (\sum x)^2}$$

$$b = \frac{\sum y - m(\sum x)}{N}$$

où N est le nombre de points, $\sum xy$ est la somme des produits des coordonnées, $\sum x$ est la somme des abscisses, et $\sum y$ est la somme des ordonnées.

Exemple 2 - Régression linéaire

2. Méthode de descente de gradient

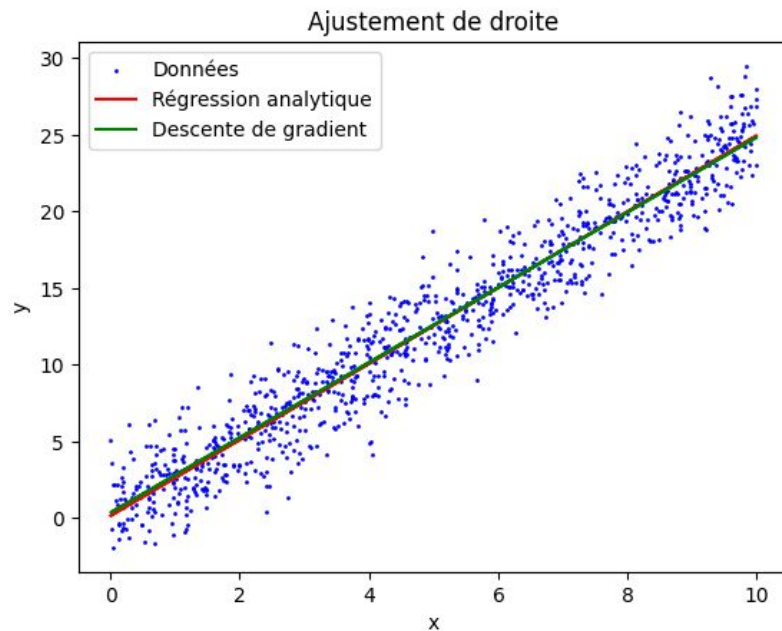

La méthode de descente de gradient consiste à itérer sur les coefficients m et b en suivant le gradient de la fonction de coût (MSE) par rapport à ces coefficients. Voici les étapes :


1. Initialiser m et b à des valeurs aléatoires.
2. Calculer la prédiction pour chaque point.
3. Calculer le MSE et le gradient.
4. Mettre à jour m et b en fonction du gradient.
5. Répéter jusqu'à convergence.

Exemple 2 - Régression linéaire

La fonction à minimiser :
$$J(m, b) = \frac{1}{N} \sum_{i=1}^N (y_i - (mx_i + b))^2$$


Le code exemple peut être trouvé [ici](#)





Passons à la pratique !

Rendez-vous au TD 1, exercices partie II




Jour 1 :
Partie 3

Optimisation avec contraintes

Optimisation avec contraintes

Objectif : Trouver le minimum ou le maximum d'une fonction tout en respectant des restrictions sur les variables.

Exemple : Un fermier souhaite clôturer un champ rectangulaire pour ses moutons. Il dispose de 100 mètres de clôture. Quelles dimensions doit-il choisir pour maximiser la surface du champ ?



Types de contraintes

Contraintes d'égalité



Une entreprise dispose d'un **budget** de 10 000€ pour sa campagne publicitaire.

Si x représente le montant dépensé en publicité en ligne et y le montant dépensé en publicité télévisée, la contrainte d'égalité s'écrit :

$$x + y = 10000$$

Contraintes d'inégalité



Un entrepôt a une **capacité de stockage** maximale de 1000 palettes.

Si x représente le nombre de palettes stockées, la contrainte d'inégalité s'écrit :

$$x - 1000 \leq 0 \text{ ou encore } x \leq 1000$$

Méthodes de résolution (cas d'égalité)

Minimiser (ou maximiser) une fonction objectif sous la contrainte .

Substitution :

Exprimer une variable en fonction des autres à partir de la contrainte .

Substituer cette expression dans la fonction objectif pour obtenir un problème sans contrainte.

Multiplicateurs de Lagrange :

Nouvelle variable λ (multiplicateur de Lagrange) permet de former le **Lagrangien** :

$$L(x, \lambda) = f(x) + \lambda g(x)$$

Points critiques du Lagrangien = solutions optimales

Méthodes numériques : méthodes de pénalisation, méthodes de projection...

Exemple : Maximiser une surface

Maximiser la surface d'un enclos rectangulaire avec **100 mètres de clôture**.

➤ **Variables :**


- x : longueur du rectangle
- y : largeur du rectangle

➤ **Fonction objectif :**

- Surface à maximiser : $A(x, y) = x * y$

➤ **Contrainte :**

- périmètre : $2x + 2y = 100$



Exemple : Maximiser une surface

Maximiser la surface d'un enclos rectangulaire avec **100 mètres de clôture**.

➤ **Variables :**

- x : longueur du rectangle
- y : largeur du rectangle



➤ **Fonction objectif :**

- Surface à maximiser : $A(x, y) = x * y$

À vous ! Quelle est la surface optimale ?

Indice : procéder par substitution

➤ **Contrainte :**

- périmètre : $2x + 2y = 100$

Méthodes de résolution (cas d'inégalité)

Minimiser (ou maximiser) une fonction objectif sous la contrainte $h(x) < 0$

Méthodes de résolution :

- **Conditions KKT** : Conditions nécessaires d'optimalité utilisant le Lagrangien.
- **Pénalisation** : Ajouter une pénalité pour les contraintes violées.
- **Projection** : Projeter la solution sur l'ensemble admissible.
- **Primitives-duales** : Résoudre le problème primal et dual simultanément.
- ...



Passons à la pratique !

Rendez-vous au TD 1, exercices partie III



Jour 1:
Partie 4

Optimisation avec Python

Importance des outils numériques

- **Résolution de problèmes complexes :** Les problèmes d'optimisation réels sont souvent de grande dimension et nécessitent des outils numériques pour être résolus.
- **Expérimentation et analyse :** Python permet de tester facilement différents algorithmes et paramètres, et d'analyser les résultats.
- **Prototypage rapide :** Python est un langage idéal pour le prototypage rapide d'algorithmes d'optimisation.

Librairies d'optimisation en Python



scipy.optimize :

- `minimize` : Fonction générale pour minimiser une fonction scalaire.
- `minimize_scalar` : Pour les fonctions univariées.
- `linprog` : Pour la programmation linéaire.
- `root` : Pour trouver les racines d'une fonction.


Autres librairies :

- `cvxopt` : Pour l'optimisation convexe.
- `PuLP` : Pour la programmation linéaire en nombres entiers.
- `scikit-optimize` : Pour l'optimisation de fonctions coûteuses à évaluer.



Optimization with PuLP

PuLP is an linear and mixed integer programming modeler written in Python.



Passons maintenant à la pratique :

Rendez-vous au TD 1, exercices partie IV



Jour 2 :
Partie 1

Introduction à l'optimisation non différentiable (convexe)

Le monde non lisse

Motivation : Pourquoi s'intéresser à l'optimisation non différentiable ?

- De nombreux problèmes d'optimisation dans la vie réelle impliquent des fonctions non différentiables.
- Les méthodes classiques d'optimisation (gradient, Newton, etc.) ne fonctionnent pas pour ces problèmes.

Exemples de problèmes non différentiables :

- En Machine Learning : SVM, régularisation L1
- En ingénierie : conception optimale, planification de trajectoires
- En économie : optimisation de portefeuille, tarification



Pourquoi les méthodes classiques ne fonctionnent pas ?

Rappel des méthodes classiques :

- Descente de gradient : utilise le gradient pour trouver la direction de descente.
- Méthode de Newton : utilise la Hessienne pour approximer la fonction par une parabole.


Limitations : Ces méthodes nécessitent que la fonction objectif soit différentiable (lisse).

Exemple : Minimiser la norme $L1$

Problème : Minimisation de la Norme $L1$

$$f(\mathbf{x}, \mathbf{y}) = |x| + |y|$$

- Les valeurs absolues créent des "arêtes" dans le graphe de la fonction



Aperçu des méthodes d'optimisation non différentiable

Méthodes de sous-gradient :

- Généralisent la descente de gradient en utilisant un sous-gradient au lieu du gradient.
- Permettent de minimiser des fonctions convexes non différentiables.

Méthodes de faisceaux :

- Construisent une approximation linéaire par morceaux de la fonction objectif.
- Plus complexes mais souvent plus efficaces que les méthodes de sous-gradient.

Autres méthodes :

- Méthodes proximales
- Méthodes de point intérieur

Méthode	Principe	Avantages	Inconvénients
<i>Sous-gradient</i>	Généralisation de la descente de gradient	Simple à implémenter, peu coûteuse en calcul.	Convergence lente, sensible au choix du pas.
<i>Faisceaux</i>	Approximation linéaire par morceaux de la fonction objectif.	Bonne convergence, efficace pour les problèmes convexes.	Plus complexe à implémenter, coûteuse en mémoire.
<i>Méthodes proximales</i>	Utilise un opérateur proximal.	Efficace pour les fonctions mixte différentiable/non différentiable	Nécessite le calcul de l'opérateur proximal, qui peut être coûteux.
<i>Méthodes du point intérieur</i>	Extension des méthodes de point intérieur pour l'optimisation linéaire.	Bonne convergence pour les problèmes convexes avec contraintes.	Complexe à implémenter, coûteuse en calcul.

Concepts Fondamentaux


Différentiabilité et non-différentiabilité

Différentiabilité :


- Intuitivement : une fonction est différentiable si elle n'a pas de "cassure" ou de "point anguleux".
- Formellement : une fonction est différentiable en un point si elle admet une dérivée en ce point.

Non-différentiabilité :


- Une fonction est non différentiable si elle n'est pas différentiable en au moins un point.
- Exemples : $f(x) = |x|$, $g(x) = \max(0, x)$ pour x réel



Cusp / Corner



Discontinuous



Vertical Tangent


Différentiabilité et non-différentiabilité

Différentiabilité :

- Intuitivement : une fonction est différentiable si elle n'a pas de "cassure" ou de "point anguleux".
- Formellement : une fonction est différentiable en un point si elle admet une dérivée en ce point.

Non-différentiabilité :

- Une fonction est non différentiable si elle n'est pas différentiable en au moins un point.
- Exemples : $f(x) = |x|$, $g(x) = \max(0, x)$ pour x réel



Sous-gradient


Motivation : Comment généraliser la notion de gradient pour les fonctions non différentiables ?

Sous-gradient : Un vecteur qui "sous-estime" la fonction en un point donné.

Définition :

g est un sous-gradient de **f** en **x** si pour tout **y** , on a :

$$f(y) \geq f(x) + g^T(y - x)$$




Sous-différentiel

Sous-différentiel : L'ensemble de tous les sous-gradients de f en x noté $\partial f(x)$

Pour les fonctions convexes, la sous-différentiel n'est jamais vide (il y a toujours un sous-gradient)

- $\partial f(x_1) = g_1$
- $\partial f(x_2) = g_2, g_3$




Exemple 1 - Fonction valeur absolue

Fonction : $f(x) = |x|$

Sous-différentiel :

- si $x > 0$ $\partial f(x) = 1$
- si $x = 0$ $\partial f(x) = [-1, 1]$
- si $x < 0$ $\partial f(x) = -1$





Exemple 2 - Fonction maximum

Fonction : $f(x) = \max(0, x)$

Sous-différentiel :

- si $x < 0$ $\partial f(x) = 0$
- si $x = 0$ $\partial f(x) = [0, 1]$
- si $x > 0$ $\partial f(x) = 1$





Place à la pratique

Rendez-vous au TD 2, exercices partie I



Jour 2 :
Partie 2


Méthode des sous-gradients

Principe de la méthode des sous-gradients

C'est une généralisation de la descente de gradient :

- Rappel : la descente de gradient utilise le gradient pour trouver la direction de descente.
- Problème : le gradient n'est pas défini pour les fonctions non différentiables.
- Solution : utiliser un **sous-gradient** à la place du gradient.

Idée intuitive : Le sous-gradient donne une direction de "descente approximative".



Méthode des sous-gradients

Algorithme :

1. Initialiser x_0
2. Pour $k = 0, 1, 2, \dots$ répéter jusqu'à convergence :
 - Calculer **un sous-gradient** $g_k \in \partial f(x_k)$
 - Choisir un pas de descente α_k
 - Mettre à jour : $x_{k+1} = x_k - \alpha_k g_k$

Choix du pas de “descente”

Importance du pas : Influence la vitesse de convergence et la stabilité de l'algorithme.

Types de pas :


- **Pas constant :** (même valeur à chaque itération) $\alpha_k = \alpha$
- **Pas décroissant :** (diminue progressivement)
 - Exemples : $\alpha_k \rightarrow 0$ $\alpha_k = \frac{1}{\sqrt{k}}$ $\alpha_k = \frac{1}{k}$
- **Pas adaptatif :** Ajusté en fonction du comportement de l'algorithme.

Convergence de la méthode

Conditions de convergence :

- La fonction objectif doit être convexe (mais la convergence est assurée)
- Le pas de descente doit satisfaire certaines conditions (e.g., être suffisamment petit).


Vitesse de convergence : Généralement plus lente que la descente de gradient classique.



Quelques exercices sur la méthode

Rendez-vous au TD 2, exercices partie II


TP 1 - Régression avec MAE




La MAE (*Mean Absolute Error*) est une fonction non différentiable.

Utilisons la MAE pour ajuster un modèle de régression

Créez une copie puis répondez aux questions du [notebook suivant](#)



TP 2 - Norme L1




Nous allons voir différentes méthodes pour chercher le minimum de la norme L1 :

- Par une descente du gradient naïve
- Par un lissage de la fonction
- Par la méthode des sous-gradients

Rendez-vous au [notebook suivant](#).

Créez une copie puis répondez aux questions par des cellules de code et markdown



TP 3 - Débruitage



Reference Image



Noisy Image



Denoised Image

Rendez-vous dans le notebook suivant (créez une copie, puis suivez les questions)

<https://colab.research.google.com/drive/16vGEETIT1SgV6K11urhoH1uRtiywLqE?usp=sharing>